데이터 유형과 구조

자료구조

➢ R에서 제공하는 주요 자료구조(객체 타입)

- Vector : 동일 데이터 타입을 갖는 1차원 배열
- Matrix : 동일 데이터 타입을 갖는 2차원 배열
- Array : 동일 데이터 타입을 갖는 다차원 배열
- List : 서로 다른 데이터 구조(Vector, Data Frame, Array, List) 중첩
- Data Frame : 열 단위로 서로 다른 데이터 타입을 갖는 배열

  -> 2차원 테이블 구조(DB 테이블과 유사)

자료구조

1) Vector 자료구조

- R의 기본 데이터 구조
- 1차원 배열 형태
  - ✓ 접근 : [index] : 1부터 시작
- 동일한 타입의 데이터만 저장 가능
- 벡터 데이터 생성 함수 : c(), seq(), rep()
- 벡터 데이터 처리 함수 : union(), setdiff(), intersect()

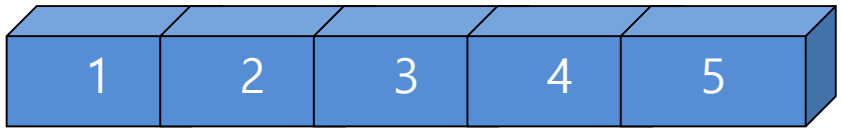

Vector

자료구조

2) Matrix 자료구조

- 동일 데이터 타입을 갖는 2차원 배열
- 행렬(matrix) 객체
- Matrix 데이터 생성 함수
  - ✓ rbind() : 행묶음
  - ✓ cbind() : 컬럼 묶음
- Matrix 데이터 처리 함수
  - ✓ apply() : 함수적용

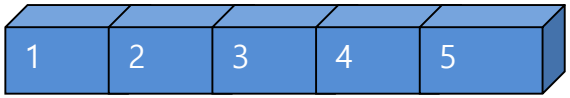

Vector

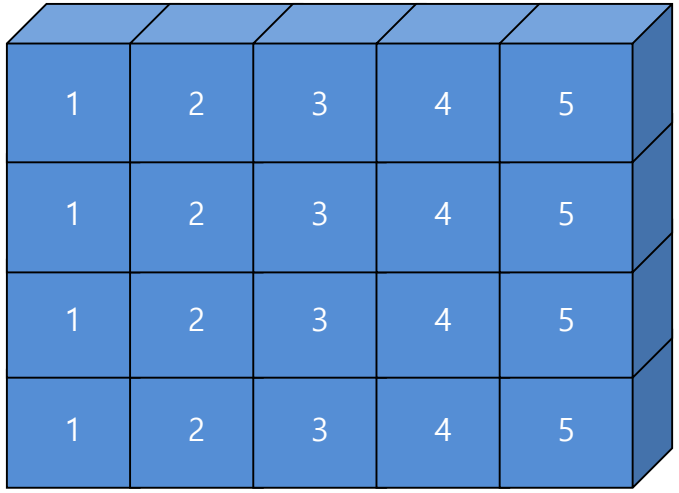

Matrix

자료구조

➢ c() 함수 이용 matrix 생성

```
m <- matrix(c(1:5))
m # 열 기준으로 행렬 생성
     #########
          [,1]
     [1,]    1
     [2,]    2
     [3,]    3
     [4,]    4
     [5,]    5
     ##########
```

```
m <- matrix(c(1:10), nrow=2) # 열 우선 2행2열 생성
m
     ##############################
          [,1] [,2] [,3] [,4] [,5]
     [1,]    1    3    5    7    9
     [2,]    2    4    6    8   10
     ##############################
m <- matrix(c(1:10), nrow=2, byrow=T) # by=T : 행 우선
m
     ##############################
          [,1] [,2] [,3] [,4] [,5]
     [1,]    1    2    3    4    5
     [2,]    6    7    8    9   10
     ##############################
```

자료구조

➢ apply() 함수

형식 | apply(X, MARGIN, Func, ...)

인수 | X : 행렬 객체

MARGIN : 1 또는 2의 값을 갖는다(1 : 행, 2 : 열).

Func : 행렬 자료에 적용할 함수.

자료구조

3) Array : 동일 데이터 타입을 갖는 다차원 배열
   - 3차원 배열 객체 생성
   - R에서 활용도 낮음

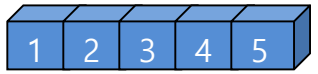

Vector

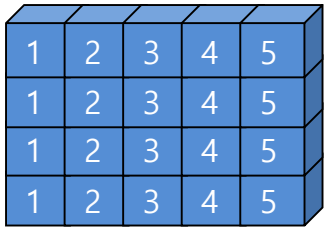

Matrix

d <- c(1:12) # 12개 벡터 객체 생성
arr <- array(d, c(3,2,2)) # 3행2열 구조 2개
arr #1~6(1면), 7~12(2면) -> 3차원 배열 객체

```
####################
, , 1

     [,1] [,2]
[1,]    1    4
[2,]    2    5
[3,]    3    6

, , 2

     [,1] [,2]
[1,]    7   10
[2,]    8   11
[3,]    9   12
##################
```

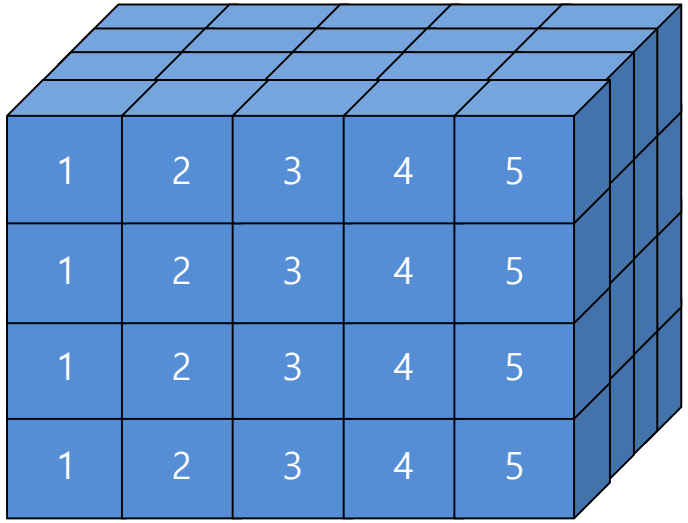

Array

자료구조

4) List : 서로 다른 데이터 구조

- Vector, Data Frame, Array, List의 중첩 구조
- c(구조체), python(딕셔너리)와 유사
- 함수 내에서 여러 값을 하나의 키로 묶어서 반환할 경우 유용함

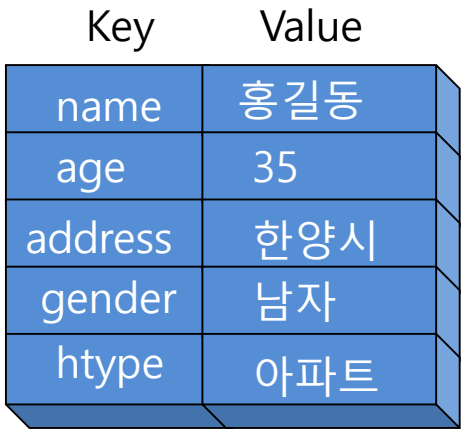


```
member <- list(name="홍길동",
               age = 35,address="한양",
               gender="남자", htype="아파트")
```

자료구조

5) Data Frame

- 리스트 보다 활용범위 넓다.
- DBMS의 테이블 구조와 유사

  (서로 다른 데이터 타입을 갖는 컬럼)
- 가장 많이 사용하는 객체 타입
- list와 Vector 혼합형

  - 컬럼 구성 : list, list 구성 : vector
- data frame 생성방법

  - Vector, Matrix, txt/excel/csv 파일

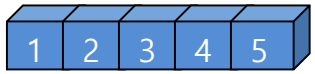

Vector

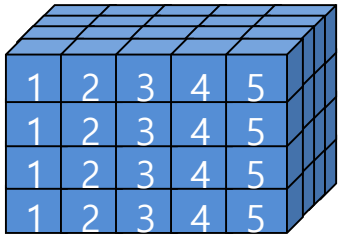

Array

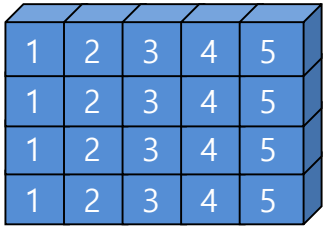

Matrix

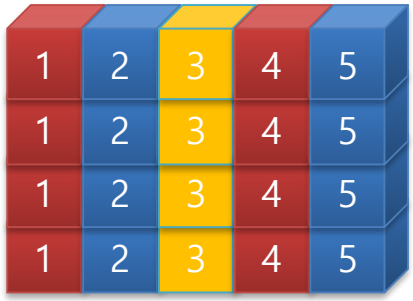

Data Frame

자료구조

- Data Frame 특징
  1. 형식) data.frame(컬럼1, 컬럼2.. 컬럼n)
  2. 컬럼 단위로 서로 다른 자료형 가능
  3. 모든 컬럼은 크기가 동일해야 함

[컬럼 구성 예]

```
id <- c(“hong”, ‘lee”, “kang”)
name <- c(“홍길동", ”이순신", ”강감찬”)
age <- c(30, 35, 45)
```

자료구조

- Data Frame 생성

1) Vector이용 객체 생성

```
no <- c(1,2,3)
name <- c("hong", "lee", "kim")
pay <- c(150,250,300)
vemp <- data.frame(NO=no, Name=name, Pay=pay) #컬럼명 지정
vemp
```

```
####################
  NO Name  Pay
1  1  hong 150
2  2  lee  250
3  3  kim  300
####################
```

자료구조

- Data Frame 생성

2) matrix이용 객체 생성

```
m <- matrix(
        c(1,"hong",150,
          2, "lee", 250,
          3, "kim", 300) ,3 ,by=T) # 행우선, 3개 리스트 생성
memp <- data.frame(m)
memp
    ##################
      X1   X2   X3  <- 기본 컬럼명
    1  1 hong 150
    2  2  lee  250
    3  3  kim  300
    ##################
```

자료구조

- Data Frame 생성

3) txt파일 이용 객체 생성

```
getwd()
setwd("c:/workspaces/Rwork/Data")
txtemp <- read.table('emp.txt', header=T, sep="") # 제목 있음, 공백 구분
txtemp
```

```
####################
   사번 이름  급여
1  101 hong  150
2  201  lee   250
3  301  kim   300
####################
```

자료구조

- Data Frame 생성

4) csv파일 이용 객체 생성

```
getwd()
csvtemp <- read.csv('emp.csv', header=T) # 제목 있음, 컴마 구분
csvtemp
```

```
####################
   사번   이름   급여
1  101 홍길동  150
2  102 이순신  450
3  103 강감찬  500
4  104 유관순  350
5  105 김유신  400
####################
```

자료구조

```
# 데이터 프레임 검색 -> 벡터 결과 반환
df$x # 형식)변수$컬럼
# 데이터 프레임 처리함수
str(df) # 테이블 구조보기
```

```
summary(df)  # 요약함수
################################
       x               y      z
Min.   : 1   Min.   : 2   a:1
1st Qu.: 2   1st Qu.: 4   b:1
Median : 3   Median : 6   c:1
Mean   : 3   Mean   : 6   d:1
3rd Qu.: 4   3rd Qu.: 8   e:1
Max.   : 5   Max.   :10
################################
```

자료구조

```
apply(df[, c(1,2)],2, sum) # 컬럼(열)단위 합계
# x  y
# 15 30
```

```
# 데이터프레임 대상 조건에 만족하는 서브셋 만들기
x1 <- subset(df, x>=3) # x가 3이상인 레코드 대상 서브셋 생성
x1
y1 <- subset(df, y<=8) # y가 8이하인 레코드 대상 서브셋 생성
y1
xy <- subset(df, x>=2 & y<=6) # 2개 조건이 참인 레코드 대상 서브셋 생성
xy
```

자료구조

- Data Join

```
h <- data.frame(id=c(1,2), h=c(180,175))
w <- data.frame(id=c(1,2), w=c(80,75))

# id 컬럼으로 data.frame 조인
user3 <- merge(h, w, by.x="id", by.y="id")
user3
#      id   h  w
#  1   1 180 80
#  2   2 175 75
```

자료구조

➢ stringr()과 정규표현식

- install.packages("stringr") # 패키지 설치
- library(stringr) # in memory
- str_extract("abcd12aaa33", "[0-9]{2}") # 연속된 숫자2개가 첫번째 발견 항목
- str_extract_all("abcd12aaa33", "[0-9]{2}") # 모두
- d <- c("김길동","유관순","강감찬","김길동")
- str_replace(d, "김길동","홍길동") # 문자열 교체
- subs <- str_sub("abcd12aaa33", 3,6) # 서브스트링 생성
- subs # "cd12"

자료구조

- Stringr 패키지에서 제공하는 주요 함수

  - str_length () : 문자열 길이 리턴
  - str_join : 문자열 연결
  - str_sub() : 범위에 해당하는 부분 문자열 출력
  - str_split() : 기준문자를 중심으로 부분 문자열 리스트 출력
  - str_replace : 문자열 교체
  - str_extract() : 문자열의 위치(index) 리턴
  - str_locate() : 문자열에서 특정 문자열 패턴의 첫번째 위치 찾기
  - str_locate_all() : 문자열에서 특정 문자열 패턴의 전체 위치 찾기
    - ✓ 문자열 패턴은 정규 표현식(Regular Expression) 이용
    - ✓ 참고 사이트 : 위키백과 정규 표현식

자료구조

➢ 위키백과 정규 표현식

http://ko.wikipedia.org/wiki/%EC%A0%95%EA%B7%9C_%ED%91%9C%ED%98%84%EC%8B%9D

식	기능	설명
.	문자	1개의 문자와 일치한다. 단일행 모드에서는 새줄 문자를 제외한다.
₩	이스케이프	특수 문자를 식에 문자 자체로 포함한다.
¦	선택	여러 식 중에서 하나를 선택한다. 예를 들어, "abc¦adc"는 abc와 adc 문자열을 모두 포함한다.
^	부정	문자 클래스 안의 문자를 제외한 나머지를 선택한다. 예를 들면 [^abc]d는 ad, bd, cd는 포함하지 않고 ed, fd 등을 포함한다. [^a-z]는 알파벳 소문자로 시작하지 않는 모든 문자를 의미한다.
[]	문자 클래스	"["과 "]" 사이의 문자 중 하나를 선택한다. "¦"를 여러 개 쓴 것과 같은 의미이다. 예를 들면 [abc]d는 ad, bd, cd를 뜻한다. 또한, "-" 기호와 함께 쓰면 범위를 지정할 수 있다. "[a-z]"는 a부터 z까지 중 하나, "[1-9]"는 1부터 9까지 중의 하나를 의미한다.
()	하위식	여러 식을 하나로 묶을 수 있다. "abc¦adc"와 "a(b¦d)c"는 같은 의미를 가진다.
*	0회 이상	0개 이상의 문자를 포함한다. "a*b"는 "b", "ab", "aab", "aaab"를 포함한다.
+	1회 이상	"a+b"는 "ab", "aab", "aaab"를 포함하지만 "b"는 포함하지 않는다.
?	0 또는 1회	"a?b"는 "b", "ab"를 포함한다.
{m}	m회	"a{3}b"는 "aaab"만 포함한다.
{m,}	m회 이상	"a{2,}b"는 "aab", "aaab", "aaaab"를 포함한다. "ab"는 포함되지 않는다.
{m, n}	m회 이상 n회 이하	"a{1,3}b"는 "ab", "aab", "aaab"를 포함하지만, "b"나 "aaaab"는 포함하지 않는다.